

Detecção de Pivôs com *Deep Learning* em Imagens de Satélite e Generalização em Municípios do Rio Grande do Sul

Emanuel de Lara Ruas¹, Edimar Manica¹

¹Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Sul - *Campus Ibirubá*
Rua Nelsi Ribas Fritsch, 1111 – CEP: 98200-000 – Ibirubá – RS – Brasil

Abstract. *Center pivot irrigation is essential for Brazilian agriculture, but official location data are updated sporadically, hindering planning and management. This work evaluates the geographic generalization capability of a U-Net architecture trained with public data to detect Center Pivot Irrigation Systems (CPIS) in Landsat imagery. Using the dataset from Liu et al. (2023), the model was trained and validated, achieving IoU of 81.12% and Precision of 94.23%. The model was then evaluated in a region not previously explored in the literature: the municipalities of the Alto Jacuí Municipalities Association (AMAJA), in Rio Grande do Sul, for which an updated dataset and validated reference masks were constructed. Results indicate IoU of 67.08% and Dice Score of 80.31% in the geographic validation, with the largest drop in IoU (-17.31%) and the smallest in Recall (-9.03%). Precision and Dice Score presented intermediate drops of -11.77% and -10.35%, respectively. The main contribution is the validation of the approach in a new geographic context, demonstrating its potential as a support tool for CPIS mapping, with caveats for improvements through domain adaptation.*

Resumo. *A irrigação por pivô central é essencial para a agricultura brasileira, mas os dados oficiais de sua localização são atualizados esporadicamente, dificultando o planejamento e a gestão. Este trabalho avalia a capacidade de generalização geográfica de uma arquitetura U-Net treinada com dados públicos para detectar Sistemas de Irrigação por Pivô Central (SIPC) em imagens Landsat. Utilizando a base de dados de Liu et al. (2023), o modelo foi treinado e validado, alcançando IoU de 81,12% e Precisão de 94,23%. Em seguida, avaliou-se o modelo em uma região não explorada na literatura: os municípios da Associação dos Municípios do Alto Jacuí (AMAJA), no Rio Grande do Sul, para a qual foi construída uma base de dados atualizada e máscaras de referência validadas. Os resultados indicam IoU de 67,08% e Dice Score de 80,31% na validação geográfica, com maior queda no IoU (-17,31%) e menor na revocação (-9,03%). A precisão e o Dice Score apresentaram quedas intermediárias de -11,77% e -10,35%, respectivamente. A principal contribuição é a validação da abordagem em novo contexto geográfico, demonstrando seu potencial como ferramenta de suporte ao mapeamento de SIPCs, com ressalvas para melhorias com adaptação de domínio.*

1. Introdução

A irrigação consiste em fornecer água às plantas de forma controlada, complementando a precipitação natural quando esta é escassa ou mal distribuída. Entre os sistemas de

irrigação, o Sistema de Irrigação por Pivô Central (SIPC) destaca-se como uma das tecnologias mais eficientes para grandes áreas. E devido à sua importância, a identificação precisa das áreas ocupadas por SIPCs é fundamental para a gestão de recursos hídricos e o planejamento da expansão agrícola. Do ponto de vista econômico, o mapeamento desses sistemas permite a otimização logística de insumos e a prospecção de mercado para serviços especializados. Ambientalmente, o monitoramento dos SIPCs é essencial para assegurar a conformidade com as outorgas de uso da água e avaliar impactos sobre a vegetação (ANA, 2021).

No Brasil, a Agência Nacional de Águas e Saneamento Básico (ANA) mantém um cadastro geoespacial de SIPCs, porém sua atualização ocorre em intervalos de aproximadamente dois anos, gerando defasagem entre os dados oficiais e a realidade em campo. Diante desse cenário, a identificação automática por meio de técnicas de Aprendizado Profundo (*Deep Learning*) surge como uma solução escalável.

A questão de pesquisa deste trabalho é: como um modelo de *Deep Learning*, treinado com base pública e parâmetros otimizados, se comporta ao validar a generalização geográfica para uma nova região? Para responder a essa questão, o objetivo deste estudo é avaliar a capacidade de generalização de uma rede *U-Net* para a identificação de SIPCs em uma região específica do Rio Grande do Sul. Como contribuição central, o trabalho apresenta a criação e a validação de um novo conjunto de dados rotulado para a região da Associação dos Municípios do Alto Jacuí (AMAJA).

Este documento está estruturado de forma a detalhar cada etapa desta investigação. A Seção 2 fundamenta os conceitos de irrigação, sensoriamento remoto e *Deep Learning*. A Seção 3 discute os trabalhos correlatos. A metodologia adotada para o treinamento e a validação geográfica é descrita na Seção 4, enquanto a Seção 5 discute os resultados e a análise da capacidade de generalização do modelo. Por fim, a Seção 6 reúne as conclusões e apresenta as sugestões para trabalhos futuros.

2. Revisão Bibliográfica

Para fundamentar o desenvolvimento deste trabalho, esta seção apresenta os principais conceitos teóricos envolvidos. Inicialmente, a Subseção 2.1 descreve os Sistemas de Irrigação por Pivô Central. Na sequência, a Subseção 2.2 aborda o sensoriamento remoto. Por fim, a Subseção 2.3 discute os fundamentos de *Deep Learning* e segmentação semântica.


2.1. Sistemas de Irrigação por Pivô Central

A irrigação é uma prática agrícola que consiste na aplicação controlada de água às culturas para suprir suas necessidades hídricas, especialmente em regiões onde a precipitação natural é insuficiente ou mal distribuída ao longo do ano (EVANS; SADLER, 2008). Entre os sistemas de irrigação, o Sistema de Irrigação por Pivô Central (SIPC) destaca-se como uma das tecnologias mais eficientes para grandes áreas planas.

De acordo com Evans e Sadler (2008), e conforme apresentado na Figura 1, um SIPC é composto por uma **estrutura metálica tubular** (1), dividida em **segmentos articulados** (2) e sustentada por **torres móveis com rodas motorizadas** (3), que permitem seu movimento circular ao redor de um **ponto fixo central** (4). A água é bombeada a partir desse ponto e distribuída por uma **tubulação** (5) ao longo de todo o sistema, sendo

distribuída por **aspersores** (6) posicionados na estrutura. Essa configuração permite uma cobertura uniforme da área irrigada com alta eficiência hídrica, além de reduzir significativamente a necessidade de mão de obra em comparação com métodos convencionais de irrigação (RASHID et al., 2023).

Figura 1. Componentes principais de um equipamento de SIPC.



Fonte: Adaptado de Al-Ghobari e Dewidar (2021).

A Figura 2 apresenta, à esquerda, uma imagem de satélite original do município de Cruz Alta – RS e, à direita, a mesma cena com os pivôs identificados e demarcados em vermelho para facilitar a visualização dos padrões circulares. Esse padrão, ilustrado na figura, pode ser reconhecido e utilizado como base para algoritmos de detecção automática de áreas irrigadas (SARAIWA et al., 2020). Neste trabalho, esses padrões circulares são explorados pela arquitetura *U-Net* para a segmentação semântica dos SIPCs nas imagens de satélite.

Figura 2. Padrões circulares de irrigação gerados por SIPCs no município de Cruz Alta – RS.



Fonte: Adaptado de ANA (2021).

2.2. Sensoriamento Remoto

O sensoriamento remoto é um processo que permite a coleta de informações da superfície terrestre sem contato direto, por meio da detecção da energia refletida ou emitida pelos objetos. Essa energia é captada por sensores embarcados em satélites, aeronaves ou veículos aéreos não tripulados (VANTs), possibilitando a observação contínua de grandes áreas com diferentes níveis de detalhe (JENSEN, 2007).

Conforme Shimabukuro et al. (2009), as imagens de sensoriamento remoto são classificadas por diferentes tipos de resolução. A **resolução espacial** determina o tamanho mínimo de objetos visíveis na imagem, expressa pelo tamanho do *pixel* em metros. A

resolução espectral indica o número e a largura das bandas de comprimento de onda captadas pelo sensor, onde cada banda corresponde a uma faixa específica do espectro eletromagnético (como o visível, o infravermelho próximo ou o infravermelho de ondas curtas), e a combinação dessas bandas permite distinguir diferentes alvos na superfície terrestre com base em suas assinaturas espectrais. Por fim, a **resolução temporal** refere-se à frequência com que o sensor revisita a mesma região, influenciando a capacidade de monitorar mudanças ao longo do tempo.

Neste trabalho, foram utilizadas imagens do programa Landsat¹, que oferecem resolução espacial de 30 m nas bandas multispectrais e resolução temporal de 16 dias.

2.3. Deep Learning

O *Deep Learning* (Aprendizado Profundo) é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas ocultas para aprender representações complexas e hierárquicas a partir de grandes volumes de dados. Dentre as arquiteturas mais consolidadas no *Deep Learning*, destacam-se as *CNNs* (*Convolutional Neural Networks* - Redes Neurais Convolucionais), que operam sobre dados estruturados em grade, como imagens, extraindo automaticamente características visuais relevantes. Uma das principais vantagens das *CNNs* é a capacidade de aprender diretamente dos dados brutos, eliminando a necessidade de engenharia manual de atributos, comum em abordagens anteriores de visão computacional (LECUN; BENGIO; HINTON, 2015).

Enquanto a classificação tradicional de imagens atribui um único rótulo para toda a imagem, a segmentação semântica refina esse processo ao associar uma classe a cada *pixel* da imagem. Essa granularidade é especialmente relevante em contextos que demandam delineamento preciso de objetos, como a identificação de áreas irrigadas por SIPC, onde a acurácia espacial é fundamental para análises agrônomicas e de gestão hídrica (YUAN; SHI; GU, 2021).

Para esse tipo de tarefa, uma das arquiteturas mais utilizadas é a *U-Net*. De acordo com Ronneberger, Fischer e Brox (2015), a *U-Net* é composta por um **caminho contrativo** (codificador), responsável por capturar o contexto da imagem, e um **caminho expansivo** (decodificador), que reconstrói a resolução espacial. Um diferencial dessa arquitetura são as **conexões de atalho** (*skip connections*) entre as camadas do codificador e decodificador, que permitem preservar detalhes espaciais relevantes e produzem segmentações com contornos mais nítidos.

3. Trabalhos Correlatos

Nesta seção, são apresentados trabalhos correlatos que abordam a detecção automática de Sistemas de Irrigação por Pivô Central (SIPC) por meio de técnicas de sensoriamento remoto e aprendizado profundo, com ênfase em arquiteturas de *CNNs* aplicadas à segmentação de imagens de satélite. A revisão da literatura foi conduzida na plataforma *Google Scholar*², utilizando as palavras-chave "*center pivot irrigation*", "*seman-*

¹O programa Landsat, iniciado em 1972 pela NASA em parceria com o USGS, é um dos mais longevos e consolidados programas de observação da Terra (U.S. Geological Survey (USGS); National Aeronautics and Space Administration (NASA), 2024).

²O *Google Scholar* é um mecanismo de busca acadêmico gratuito que indexa artigos, teses, livros, resumos e pareceres jurídicos de editoras acadêmicas, sociedades profissionais, repositórios online, universidades e outros sites (Google, 2026).

tic segmentation", *"deep learning"*, *"convolutional neural networks"* e *"remote sensing"*, combinadas com operadores booleanos (*AND*, *OR*), no recorte temporal de 2020 a 2025.

A busca inicial retornou 47 artigos, dos quais 4 foram selecionados após a aplicação dos seguintes critérios de inclusão: (i) aplicação de técnicas de *Deep Learning* para segmentação ou detecção de SIPC's; (ii) apresentação de métricas quantitativas de desempenho; (iii) trabalhos com descrição clara da metodologia e dos dados utilizados; e (iv) disponibilidade de dados de validação ou reprodutibilidade. Foram excluídos estudos que empregavam exclusivamente métodos tradicionais de processamento de imagens, bem como aqueles que não apresentavam resultados quantitativos. Priorizou-se a inclusão de trabalhos no contexto geográfico brasileiro, onde o mapeamento de pivôs centrais apresenta desafios específicos relacionados à sazonalidade e à diversidade de biomas, complementados por estudos internacionais relevantes para comparação metodológica.

No contexto brasileiro, Albuquerque (2022) aplicou e comparou diferentes arquiteturas de *CNNs*, incluindo *U-Net*, *Deep ResUnet* e *Mask R-CNN*, utilizando imagens dos satélites Landsat-8, Sentinel-1 (SAR) e Sentinel-2 (MSI). Sua pesquisa alcançou precisão superior a 96% e revocação acima de 90%, e abordou desafios como a reconstrução de mosaicos para grandes áreas e o uso de dados multitemporais para lidar com a cobertura de nuvens.

Ainda no cenário nacional, Saraiva et al. (2020) propuseram um método para detectar SIPC's no bioma Cerrado utilizando a arquitetura *U-Net* aplicada a imagens de altíssima resolução espacial da constelação *PlanetScope*³. Os autores reportaram uma precisão de 99% e revocação de 88% na detecção dos pivôs, reforçando o potencial das *CNNs* para segmentação semântica nesse tipo de aplicação.

Em uma escala mais abrangente, Liu et al. (2023) produziram mapas anuais de SIPC's para todo o território brasileiro no período de 1985 a 2021, utilizando imagens Landsat 5, 7 e 8 com resolução de 30 m. O estudo empregou a arquitetura *U-Net* e um conjunto de dados representativo de diferentes zonas climáticas do Brasil, alcançando *mIoU* médio de 94,70% e precisão de 99,60% sobre o conjunto de teste. A base de dados gerada por esse estudo é publicamente disponível e foi utilizada como base de treinamento no presente trabalho.

Em âmbito internacional, Cooley, Maxwell e Smith (2021) desenvolveram uma abordagem de *Deep Learning*, baseada em uma *U-Net* modificada a partir do trabalho de Saraiva et al. (2020), para localizar SIPC sobre o Aquífero Ogallala, nos Estados Unidos da América (EUA). Utilizando imagens dos satélites Landsat 5 e 7 (resolução de 30 m) e dados de treinamento do estado de Nebraska, alcançaram 98% de acurácia e 88% de revocação a nível de *pixel*.

A análise comparativa dos trabalhos correlatos, conforme resumido na Tabela 1, revela que em termos de **método** todos fazem uso de arquiteturas baseadas em *U-Net*. As **fontes de dados** apresentam variações, integrando imagens dos satélites Landsat, Sentinel e PlanetScope. O **contexto geográfico** é um importante ponto de distinção, com Albuquerque (2022), Saraiva et al. (2020) e Liu et al. (2023) concentrando-se no Brasil, tornando seus estudos particularmente relevantes para a realidade nacional, enquanto

³PlanetScope é uma constelação de satélites de observação da Terra operada pela *Planet Labs*, composta por centenas de nanossatélites do tipo *CubeSat* (European Space Agency (ESA), 2026).

Cooley, Maxwell e Smith (2021) direcionam sua pesquisa para os EUA. Por fim, as **principais métricas / resultados** demonstram a performance de cada abordagem, com Albuquerque (2022) reportando revocação maior que 92% e Precisão superior a 96% e Saraiva et al. (2020) alcançando 99% de Precisão e 88% de revocação.

Em comparação com os trabalhos correlatos, o presente trabalho se diferencia principalmente pela validação em uma região geograficamente distinta não explorada na literatura, o que permite avaliar a capacidade de generalização do modelo para contextos com características edafoclimáticas distintas.

Tabela 1. Comparação dos Trabalhos Correlatos.

Característica	Albuquerque (2022)	Saraiva et al. (2020)	Cooley, Maxwell e Smith (2021)	Liu et al. (2023)
Objetivo	Aprimorar mapeamento automático de SIPC	Detectar e mapear SIPC	Localizar SIPC	Produzir mapas anuais de SIPC (1985–2021)
Método	<i>U-Net, Deep ResUnet</i>	<i>U-Net</i>	<i>U-Net</i> modificada	<i>U-Net</i>
Fontes de Dados	Landsat-8, Sentinel 1 e 2	PlanetScope	Landsat 5 e 7	Landsat 5, 7 e 8
Contexto Geográfico	Brasil Central	Bioma Cerrado, Brasil	Aquífero Ogallala, EUA	Brasil (1985–2021)
Principais Métricas / Resultados	Precisão > 96%, revocação > 90%	Precisão: 99%, revocação: 88%	Acurácia: 98%, revocação: 88%	Precisão: 99,60%, revocação: 94,80%

Fonte: Autor.


4. Metodologia

A metodologia adotada neste trabalho segue uma abordagem adaptada do **CRISP-DM** (*Cross-Industry Standard Process for Data Mining* - Processo Padrão Intersetorial para Mineração de Dados), um modelo de processo amplamente utilizado para projetos de mineração de dados e aprendizado de máquina (MARTÍNEZ-PLUMED et al., 2021).

De acordo com Shearer (2000), o **CRISP-DM** é composto por seis fases principais: (1) **Entendimento do Negócio** — compreensão dos objetivos e requisitos do projeto sob a perspectiva do negócio, traduzindo-os em problemas de mineração de dados; (2) **Entendimento dos Dados** — coleta, descrição, exploração e verificação da qualidade dos dados disponíveis; (3) **Preparação dos Dados** — seleção, limpeza, transformação e formatação dos dados para aplicação dos modelos; (4) **Modelagem** — aplicação de técnicas de modelagem, como redes neurais, árvores de decisão ou regressão, com ajuste de hiperparâmetros; (5) **Avaliação** — análise dos resultados obtidos, verificação se os objetivos de negócio foram atendidos e revisão do processo; (6) **Implantação** — organização, documentação e implementação do modelo em produção, com monitoramento e manutenção contínuos.

A Figura 3 ilustra o fluxo do *CRISP-DM*, evidenciando sua característica iterativa. As próximas subseções detalham como cada uma das etapas foi realizada. A etapa de implantação, por sua vez, não foi realizada por estar fora do escopo do trabalho. Como alternativa, realizou-se uma validação do modelo em uma região geográfica distinta, que visa avaliar a capacidade de generalização do modelo para novos contextos.

Figura 3. Fluxo da metodologia adotada.



Fonte: Adaptado de Shearer (2000).

4.1. Entendimento dos Dados

Nesta etapa, buscou-se compreender as características dos dados utilizados no trabalho, bem como sua adequação aos objetivos propostos. Foram utilizadas duas bases de dados distintas: uma base de dados geral para o treinamento do modelo, e uma base de dados específica de uma região para a validação da capacidade de generalização geográfica. A validação da generalização geográfica consiste em avaliar o desempenho do modelo em uma região diferente daquela utilizada no treinamento, com o objetivo de verificar se o modelo é capaz de reconhecer padrões de SIPCs em contextos ambientais, espectrais e de uso do solo distintos.

A base de dados utilizada para treinamento foi a disponibilizada por Liu et al. (2023) no repositório Zenodo⁴. Essa base contém imagens compostas anuais com três bandas (*EVI_max*, *BSI_max*, *green_median*) em resolução espacial de 30 m, cobrindo todo o território brasileiro para os anos de 1985 a 2021. Uma imagem composta anual é gerada a partir da combinação de múltiplas imagens adquiridas ao longo de um mesmo

⁴Disponível em: <<https://zenodo.org/records/10046320>>. Acesso em: 02 jul. 2026.

ano, selecionando-se para cada *pixel* o valor máximo de determinados índices (como *EVI* e *BSI*) ou a mediana de uma banda (como o verde), visando obter uma representação livre de nuvens e com as características espectrais mais representativas do período.

As três bandas utilizadas são: (i) **EVI_max** (*Enhanced Vegetation Index* - Índice de Vegetação Aprimorado) máximo, que realça a presença e o vigor da vegetação; (ii) **BSI_max** (*Bare Soil Index* - Índice de Solo Exposto) máximo, que evidencia a exposição do solo, comum em áreas agrícolas após a colheita ou no preparo do plantio; e (iii) **green_median** (Mediana Verde), a mediana da banda do verde, que auxilia na distinção de diferentes coberturas do solo. A base de treinamento, embora abrangente, apresenta dados até 2021, estando portanto defasada em relação ao momento atual. As imagens são acompanhadas de máscaras de segmentação (*ground truth*), que são imagens binárias onde cada *pixel* é classificado como 1 (pertencente a um SIPC) ou 0 (fundo), permitindo que o modelo aprenda a delimitar com precisão as áreas irrigadas. Essas máscaras foram geradas a partir de dados da ANA e validadas por humanos.

Para a etapa de validação da generalização geográfica, foi construída uma base de dados atual com imagens dos municípios que compõem a Associação dos Municípios do Alto Jacuí (AMAJA)⁵. Utilizando o *Google Earth Engine*⁶, foi desenvolvido um *script* para extrair e processar imagens do satélite Landsat, com resolução espacial de 30 m (idêntica à da base de treinamento). Aplicaram-se os mesmos índices espectrais — *EVI*, *BSI* e banda do verde — utilizados na base de treinamento, descritos anteriormente.

A partir das imagens coletadas, gerou-se uma composição anual com três bandas (*EVI* máximo, *BSI* máximo e mediana do verde) para o ano de 2023, que foi exportada como imagem de composição de cores. A composição de cores refere-se à combinação das três bandas em um único arquivo de imagem, onde cada banda ocupa um canal de cor (vermelho, verde e azul), permitindo a visualização conjunta das informações espectrais. As máscaras de referência para esta região foram construídas a partir dos dados oficiais da ANA, complementadas por validação humana, seguindo o mesmo procedimento adotado na base de treinamento.

A Tabela 2 sintetiza as principais características das duas bases de dados utilizadas, organizadas segundo as três resoluções fundamentais para o sensoriamento remoto: espacial, temporal e espectral.

4.2. Preparação dos Dados

Nesta etapa, os dados brutos obtidos na fase anterior foram organizados, padronizados e transformados em um formato adequado para o treinamento do modelo de *Deep Learning*. O objetivo principal foi garantir a consistência e a qualidade dos dados de entrada, além de adotar estratégias para lidar com o desbalanceamento entre as classes, de modo a viabilizar o aprendizado eficaz da rede neural.

As imagens e máscaras já se encontravam padronizadas em 512×512 *pixels*, com valores de *pixel* normalizados entre 0 e 1, conforme o artigo original, de modo que não

⁵Disponível em: <<https://amaja.com.br/site/municipios.php>>. Acesso em: 02 jul. 2026.

⁶O Google Earth Engine é uma plataforma baseada em nuvem para processamento e análise de dados geoespaciais em escala planetária, que permite o acesso a um vasto acervo de imagens de satélite e a execução de algoritmos de forma distribuída (GORELICK et al., 2017).

Tabela 2. Características das bases de dados utilizadas.

Característica	Base de Treinamento	Base de Validação (Alto Jacuí)
Resolução Espacial	30 m (Landsat)	30 m (Landsat)
Resolução Temporal	Composição anual (1985–2021)	Composição anual (2023)
Resolução Espectral	3 bandas (<i>EVI</i> , <i>BSI</i> , <i>GREEN</i>)	3 bandas (<i>EVI</i> , <i>BSI</i> , <i>GREEN</i>)
Período dos dados	1985–2021	2023
Origem das máscaras	ANA + validação humana	ANA + validação humana

Fonte: Autor.

foram necessárias transformações adicionais. A base foi dividida em 70% para treinamento e 30% para teste conforme a estratégia de amostragem estratificada por densidade de pivôs adotada por Liu et al. (2023). Do conjunto de treinamento, separou-se aleatoriamente 10% para validação, destinada ao monitoramento do desempenho do modelo durante o treinamento e à seleção dos melhores hiperparâmetros. Para lidar com o desbalanceamento entre as classes (SIPC e não-SIPC), adotou-se a técnica *RandomMix*, que combina amostras positivas e negativas para criar novas amostras com maior proporção de *pixels* da classe SIPC, melhorando a representatividade da classe minoritária durante o treinamento (LIU et al., 2023).

Para a base de dados da região da AMAJA, as imagens foram recortadas e pré-processadas de forma idêntica à base de treinamento, garantindo que as condições de entrada do modelo fossem as mesmas. Dessa forma, as imagens de validação também foram padronizadas em 512×512 *pixels* e com valores normalizados entre 0 e 1, assegurando a compatibilidade com o modelo treinado e permitindo uma avaliação justa da capacidade de generalização geográfica.

4.3. Modelagem

Nesta etapa, o modelo de *Deep Learning* foi definido, configurado e treinado para realizar a segmentação semântica dos SIPCs nas imagens de satélite. O objetivo principal foi encontrar a combinação de hiperparâmetros e estratégias que maximizasse a capacidade do modelo de delimitar com precisão as áreas irrigadas, equilibrando desempenho e eficiência computacional.

Foram investigadas variações nos seguintes hiperparâmetros: (i) tamanho das imagens de entrada (256×256 e 512×512 *pixels*); (ii) número inicial de filtros da rede (32, 64 e 128); (iii) funções de perda (*Dice Loss*, *Tversky Loss* e *Binary Cross-Entropy*); (iv) algoritmos de otimização (RMSprop e Adam) e respectivas taxas de aprendizado (10^{-3} , 10^{-4} e 5×10^{-5}); (v) tamanho do lote (*batch size*) (8, 16 e 32); e (vi) número de épocas (25, 50, 75 e 100). A configuração que apresentou o melhor desempenho no conjunto de validação foi selecionada para a etapa de avaliação e é detalhada na Seção de Resultados.

É importante destacar que a base de dados da região da AMAJA não foi utilizada em nenhuma etapa do treinamento ou ajuste de hiperparâmetros. Essa base foi mantida isolada para a validação da generalização geográfica, descrita na Seção 4.4, garantindo que a avaliação da capacidade de generalização do modelo fosse realizada sobre dados completamente novos e não vistos durante o treinamento.

Os treinamentos foram executados em uma máquina virtual do *Google Colab*⁷ equipada com uma GPU NVIDIA A100 de 80 GB de memória e 180 GB de memória RAM. Durante o processo de treinamento, os pesos do modelo foram armazenados a cada cinco épocas, permitindo o acompanhamento da evolução do desempenho. O treinamento da arquitetura *U-Net* foi conduzido por até 100 épocas, com interrupção antecipada (*early stopping*) monitorando o valor de *Intersection over Union (IoU)* no conjunto de validação, com paciência (*patience*) de 15 épocas. Ao final, o modelo selecionado para a etapa de avaliação foi aquele que apresentou o melhor valor de *IoU*.

O código-fonte e as configurações foram organizados de forma modular, facilitando futuras adaptações, e estão disponíveis publicamente no repositório GitHub⁸.

4.4. Avaliação

Após a etapa de modelagem, o modelo selecionado foi submetido à fase de avaliação. A avaliação foi dividida em duas partes distintas, com objetivos complementares. A primeira parte consiste na avaliação do modelo treinado sobre o conjunto de dados de teste, oriundo da mesma distribuição dos dados de treinamento, com o objetivo de mensurar o desempenho da abordagem proposta em condições controladas e comparáveis à literatura. A segunda parte consiste na avaliação da capacidade de generalização geográfica do modelo, realizada sobre a base de dados da região da AMAJA, com o objetivo de verificar se o modelo é capaz de manter seu desempenho ao ser aplicado em uma região distinta, com características edafoclimáticas diferentes das áreas de treinamento.

O desempenho foi analisado por meio de métricas quantitativas amplamente empregadas na segmentação de imagens, baseadas na comparação *pixel a pixel* entre as máscaras preditas pelo modelo e as máscaras de referência. No contexto da classificação binária (SIPC e não-SIPC), as seguintes definições foram consideradas:

- **Verdadeiro Positivo (VP):** *pixels* corretamente classificados como SIPC;
- **Falso Positivo (FP):** *pixels* incorretamente classificados como SIPC;
- **Falso Negativo (FN):** *pixels* pertencentes à classe SIPC não identificados;
- **Verdadeiro Negativo (VN):** *pixels* corretamente classificados como não-SIPC.


A Figura 4 ilustra um exemplo de segmentação realizada pela abordagem proposta. A imagem de entrada (a) apresenta a composição das bandas espectrais selecionadas. A máscara de referência (b) delimita a área ocupada pelos pivôs. A predição do modelo (c) exhibe em branco os *pixels* classificados como SIPC e em preto os demais. Por fim, a sobreposição (d) evidencia os acertos e erros da segmentação: os *pixels* verdadeiro positivos em verde; os falsos positivos em vermelho; os falsos negativos em azul; e os verdadeiros negativos em preto.

Com base nessas definições, foram calculadas as métricas de **Precisão**, que avalia a capacidade do modelo em evitar falsos positivos; **Revocação** (também conhecida como *Recall*), que mede a capacidade de identificar os *pixels* pertencentes à classe SIPC; **Dice Score**, correspondente à média harmônica entre precisão e revocação; e **Intersection**

⁷O Google Colaboratory (Colab) é um ambiente de notebook Jupyter hospedado em nuvem, fornecendo acesso a recursos computacionais, incluindo GPUs e TPUs (GOOGLE, 2026).

⁸Disponível em: <<https://github.com/delaradev/unet-pivot-irrigation-identifier>>. Acesso em: 02 jul. 2026.

Figura 4. Exemplo de segmentação e avaliação da classificação SIPC vs. não-SIPC.



Fonte: Autor.

over Union (IoU), que quantifica a sobreposição entre a máscara predita e a máscara de referência. As respectivas métricas são dadas pelas fórmulas:

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (1)$$

$$\text{Revocação} = \frac{VP}{VP + FN} \quad (2)$$

$$\text{Dice Score} = 2 \times \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (3)$$

$$\text{IoU} = \frac{VP}{VP + FP + FN} \quad (4)$$

5. Resultados

Nesta seção, são apresentados e discutidos os resultados obtidos com a abordagem proposta. Inicialmente, avalia-se o desempenho do modelo *U-Net* treinado com a base de dados de Liu et al. (2023) sobre o conjunto de validação, comparando os resultados com a literatura. Em seguida, analisa-se a capacidade de generalização geográfica do modelo, aplicando-o à base de dados construída para a região da AMAJA, e discutem-se as variações de desempenho observadas. Por fim, são identificados e analisados os principais casos de falha.

5.1. Avaliação do Modelo

O melhor modelo, selecionado pelo maior *IoU* obtido na validação, correspondeu à época 94. O histórico de treinamento, resumido na Tabela 3, apresenta os melhores valores alcançados para as principais métricas de segmentação em comparação com os resultados obtidos por Liu et al. (2023), que representam a média das métricas para todos os anos (1985–2021) sobre o conjunto de teste, conforme reportado no artigo. Os valores do trabalho proposto são do melhor modelo sobre o conjunto de validação.

É importante destacar que o critério de seleção do melhor modelo foi o maior valor de *IoU* no conjunto de validação, e não a menor perda (*loss*). Essa escolha justifica-se pelo fato de o *IoU* refletir diretamente a qualidade da segmentação espacial, uma vez que mede a sobreposição entre a área predita pelo modelo e a área de referência (*ground truth*). Dessa forma, a seleção pelo maior *IoU* garante que o modelo escolhido seja aquele que melhor delinea os contornos dos pivôs.

Os resultados indicam que o modelo generalizou adequadamente para os dados de validação, com *IoU* de 81,12% e *Dice Score* de 89,58%. Embora Liu et al. (2023) reportem um *mIoU* médio de 94,70% para o conjunto de teste em todo o período analisado, os valores obtidos demonstram um bom desempenho da abordagem proposta. A precisão de 94,23% é particularmente relevante para aplicações práticas, pois indica uma baixa taxa de falsos positivos, reduzindo a ocorrência de alarmes falsos em um eventual sistema de monitoramento. A revocação de 85,36%, por sua vez, demonstra que a maior parte dos pivôs foi corretamente detectada, embora ainda haja margem para redução das omissões.

Tabela 3. Melhores métricas obtidas durante o treinamento no conjunto de validação disponibilizado por Liu et al. (2023).

Métrica	Trabalho proposto	Liu et al. (2023)
Precisão	94,23%	99,60%
Revocação	85,36%	94,80%
<i>Dice Score</i>	89,58%	97,10%
<i>IoU (Intersection over Union)</i>	81,12%	94,70%

Fonte: Autor.

5.2. Avaliação da Generalização Geográfica

A Tabela 4 apresenta as métricas de desempenho obtidas na inferência sobre as imagens da região da AMAJA, juntamente com a variação percentual em relação aos resultados obtidos no conjunto de validação original (Subseção 5.1).

Os resultados demonstram que o modelo mantém desempenho mesmo em uma região com características edafoclimáticas distintas das áreas de treinamento. O *IoU* de 67,08% e o *Dice Score* de 80,31% indicam que, embora a sobreposição espacial tenha sido reduzida, a similaridade geral entre as áreas preditas e as máscaras de referência ainda é significativa, atestando a capacidade do modelo em reconhecer os padrões circulares dos pivôs mesmo em novos contextos.

A análise das variações percentuais revela comportamentos distintos entre as métricas. A métrica com menor queda foi a revocação (-9,03%), indicando que a capacidade

Tabela 4. Métricas de desempenho obtidas na validação na região da AMAJA.

Métrica	Generalização geográfica	Variação (%)
Precisão	83,14%	-11,77%
Revocação	77,65%	-9,03%
<i>Dice Score</i>	80,31%	-10,35%
<i>IoU (Intersection over Union)</i>	67,08%	-17,31%

Fonte: Autor.

de detectar os pivôs foi a menos afetada na nova região. Por outro lado, a métrica com maior queda foi o *IoU* (-17,31%), sugerindo que a sobreposição exata entre as áreas preditas e as reais foi mais penalizada. Isso ocorre porque o *IoU* é particularmente sensível a reduções simultâneas em precisão e revocação, penalizando a interseção sobre a união. A precisão caiu 11,77% enquanto a revocação caiu 9,03%, contribuindo para essa degradação mais acentuada do *IoU*. O *Dice Score*, com queda intermediária de -10,35%, reflete o equilíbrio entre precisão e revocação, por ser uma média harmônica entre ambas.

Os resultados da validação na região da AMAJA indicam que o modelo treinado possui potencial para ser utilizado como ferramenta de suporte ao mapeamento de SIPCs em diferentes regiões do Brasil, embora com a ressalva de que ajustes adicionais, como o refinamento do conjunto de treinamento ou a adoção de técnicas de adaptação de domínio, possam ser necessários para melhorar a precisão em contextos específicos.

5.3. Casos de Falha

O modelo apresentou limitações em situações específicas, que podem ser agrupadas nas seguintes categorias:

- **Pivôs de pequenas dimensões:** SIPCs com diâmetro inferior a 150 m ocupam poucos *pixels* na resolução espacial de 30 m do Landsat, perdendo a forma circular característica e dificultando a detecção pela *U-Net*.
- **Estruturas circulares não relacionadas à irrigação:** elementos naturais ou artificiais com formato circular, como lagos, reservatórios ou talhões com geometria similar, geraram falsos positivos em algumas ocasiões, confundindo o modelo.
- **Variações sazonais e fenológicas:** em determinadas regiões, a composição anual da imagem pode não capturar o pivô em sua fase de maior contraste com o entorno (por exemplo, solo exposto *versus* vegetação densa), o que prejudica a detecção.

Essas limitações são amplamente discutidas na literatura (ALBUQUERQUE, 2022; COOLEY; MAXWELL; SMITH, 2021) e podem ser mitigadas com a adoção de imagens de maior resolução espacial, a inclusão de bandas espectrais adicionais ou a utilização de dados multitemporais que considerem a dinâmica fenológica das culturas.

6. Conclusão

Este trabalho apresentou o desenvolvimento e a avaliação de uma abordagem baseada em *Deep Learning* para a identificação automática de SIPCs em imagens de satélite, com o objetivo de superar a defasagem temporal dos dados oficiais disponíveis e oferecer uma alternativa escalável e precisa para o monitoramento dessas áreas. Utilizando a

base de dados pública gerada por Liu et al. (2023), treinou-se uma arquitetura *U-Net* que alcançou *IoU* de 81,12% e Precisão de 94,23% na segmentação de SIPCs.

A validação em uma região geograficamente distinta (os municípios que compõem a AMAJA, no Rio Grande do Sul) foi fundamental para comprovar a capacidade do modelo diante de diferentes contextos edafoclimáticos. Embora tenha sido observada uma queda nas métricas (*IoU* de 67,08% e Precisão de 83,14%), os resultados indicam que o modelo mantém sua capacidade de reconhecer os padrões circulares dos pivôs mesmo em novas regiões. A revocação, com variação de -9,03%, foi a métrica que apresentou a menor queda, indicando que a capacidade de detectar os pivôs foi a menos afetada na nova região. O *Dice Score* (-10,35%) e a precisão (-11,77%) apresentaram quedas intermediárias, enquanto o *IoU* (-17,31%) sofreu a maior degradação, por ser mais sensível a reduções simultâneas nas demais métricas.

A principal contribuição deste trabalho é a validação da abordagem proposta, baseada no padrão *CRISP-DM*, que pode ser replicado para atualizações do cadastro de SIPCs, apoiando decisões estratégicas para o setor agroindustrial, como planejamento logístico, prospecção de mercado e gestão de recursos hídricos. Como contribuição secundária, destaca-se a construção de uma base de dados atualizada para a região da AMAJA, com imagens compostas anuais e máscaras de segmentação validadas, que pode servir como referência para futuros estudos na região e para o desenvolvimento de técnicas de adaptação de domínio.

A abordagem proposta demonstra potencial para ser utilizada como ferramenta de suporte ao mapeamento de SIPCs em diferentes regiões do Brasil, embora com a ressalva de que ajustes adicionais, como a inclusão de amostras de treinamento de outras regiões ou a adoção de técnicas de adaptação de domínio, sejam necessários para melhorar a precisão em contextos específicos. Os casos de falha identificados, especialmente relacionados a pivôs de pequenas dimensões, estruturas circulares não relacionadas à irrigação e variações sazonais, indicam caminhos para aprimoramentos futuros.

Como trabalhos futuros, sugerem-se: (i) a incorporação de dados de maior resolução espacial para melhor detecção de pivôs pequenos; (ii) a exploração de arquiteturas de segmentação de instâncias para contagem individualizada de pivôs; (iii) a integração com plataformas como o *Google Earth Engine* para operacionalização em tempo real; e (iv) a expansão da validação para outras regiões brasileiras a fim de avaliar a robustez do modelo em diferentes biomas e condições climáticas.

Declaração de Utilização de Inteligência Artificial Generativa

Durante o desenvolvimento deste trabalho, o modelo de inteligência artificial generativa **DeepSeek** foi utilizado, restringindo-se sua aplicação à revisão gramatical e ao aprimoramento da clareza textual. Todas as sugestões geradas pela ferramenta foram criteriosamente analisadas e validadas, de modo a assegurar que o conteúdo final apresentasse coerência com o referencial teórico adotado e com a linha de raciocínio subjacente à pesquisa. A responsabilidade integral pela precisão das informações, pela originalidade das ideias e pela qualidade do texto exposto é assumida exclusivamente pelo autor.

Referências

- AL-GHOBARI, H.; DEWIDAR, A. Z. A comparative study of standard center pivot and growers-based modified center pivot for evaluating uniformity coefficient and water distribution. *Agronomy*, v. 11, n. 8, 2021. ISSN 2073-4395. Disponível em: <<https://www.mdpi.com/2073-4395/11/8/1675>>.
- ALBUQUERQUE, A. O. *Inteligência artificial e Sistemas de Irrigação por Pivô Central: desenvolvimento de estratégias e técnicas para o aprimoramento do mapeamento automático*. 118 p. Tese (Tese (Doutorado em Geografia)) — Universidade de Brasília, Instituto de Ciências Humanas, Distrito Federal, 2022.
- ANA. *Atlas da Irrigação: uso da água na agricultura irrigada*. 2. ed. Brasília: ANA, 2021. Disponível em: <<https://www.ana.gov.br/atlasirrigacao/>>. Acesso em: 02 julho 2026. ISBN 978-65-88101-10-0.
- COOLEY, D.; MAXWELL, R. M.; SMITH, S. M. Center pivot irrigation systems and where to find them: A deep learning approach to provide inputs to hydrologic and economic models. *Frontiers in Water*, v. 3, p. 786016, 2021. Disponível em: <<https://doi.org/10.3389/frwa.2021.786016>>. Acesso em: 02 jul. 2026.
- European Space Agency (ESA). *PlanetScope Overview*. 2026. <<https://earth.esa.int/eogateway/missions/planetscope>>. Acesso em: 03 jul. 2026.
- EVANS, R. G.; SADLER, E. J. Center pivot irrigation. In: *Design and operation of farm irrigation systems*. St. Joseph, MI, USA: ASABE, 2008. v. 2, p. 505–555.
- Google. *About Google Scholar*. 2026. <<https://scholar.google.com/intl/en/scholar/about.html>>. Acesso em: 24 jun. 2026.
- GOOGLE. *Google Colaboratory*. 2026. <<https://colab.google>>. Acesso em: 03 jul. 2026.
- GORELICK, N. et al. Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, Elsevier, 2017. Disponível em: <<https://doi.org/10.1016/j.rse.2017.06.031>>.
- JENSEN, J. R. *Remote sensing of the environment: an earth resource perspective*. 2. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007. Disponível nos acervos da editora.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015.
- LIU, X. et al. Mapping annual center-pivot irrigated cropland in brazil during the 1985–2021 period with cloud platforms and deep learning. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 205, p. 227–245, 2023. ISSN 0924-2716. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0924271623002812>>.
- MARTÍNEZ-PLUMED, F. et al. Crisp-dm twenty years later: From data mining processes to data science trajectories. *IEEE Transactions on Knowledge and Data Engineering*, v. 33, n. 8, p. 3048–3061, 2021.
- RASHID, M. et al. Sustainable water management for small farmers with center-pivot irrigation: A hydraulic and structural design perspective. *Sustainability*, v. 15, n. 23, 2023. ISSN 2071-1050. Disponível em: <<https://www.mdpi.com/2071-1050/15/23/16390>>.

RONNEBERGER, O.; FISCHER, P.; BROX, T. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. Disponível em: <<https://arxiv.org/abs/1505.04597>>.

SARAIVA, M. et al. Automatic mapping of center pivot irrigation systems from satellite images using deep learning. *Remote Sensing*, v. 12, n. 3, 2020. ISSN 2072-4292. Disponível em: <<https://www.mdpi.com/2072-4292/12/3/558>>.

SHEARER, C. The crisp-dm model: The new blueprint for data mining. *Journal of Data Warehousing*, v. 5, n. 4, p. 13–22, 2000.

SHIMABUKURO, Y. E. et al. Sensoriamento remoto e sistemas de informações geográficas aplicados ao estudo dos recursos agronômicos e florestais. *Revista Ceres*, Viçosa, v. 56, n. 4, p. 404–410, 2009.

U.S. Geological Survey (USGS); National Aeronautics and Space Administration (NASA). *The Landsat Program: A Global Record of Change*. 2024. Disponível em: <<https://www.usgs.gov/landsat/about>>. Acesso em: 02 jul. 2026.

YUAN, X.; SHI, J.; GU, L. A review of deep learning methods for semantic segmentation of remote sensing imagery. *Expert Systems with Applications*, v. 169, p. 114417, 2021. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417420310836>>.